

# Üzleti Elemzések Módszertana

## 3. Gyakorlat: Regularizált modellek

Kuknyó Dániel  
Budapesti Gazdasági Egyetem

2023/24  
2.félév

1 A gépi tanulás kihívásai

2 Polinomiális regresszió

3 Regularizált modellek

4 Módszertan

## 1 A gépi tanulás kihívásai

## 2 Polinomiális regresszió

## 3 Regularizált modellek

## 4 Módszertan

# Nincs ingyen ebéd

Ez az elv azt sugallja, hogy egy algoritmus, amely egyes feladatokon jól teljesít, nem feltétlenül fog ugyanolyan jól működni más feladatokon. **Nincs egyetemesen optimális algoritmus minden lehetséges problémára.** Ennek következményei:

- Az algoritmusokat szükséges specializálni
- Az egyes feladatokon össze kell hasonlítani különböző modellek teljesítményét
- Nincs egyetemes megoldás egyetlen problémára




# Nem reprezentatív vagy hiányos adatok

A diagramon az egy főre jutó GDP és az emberek életükkel való elégedettsége látható. A mintában nem szerepelnek a gazdagabb és szegényebb országok. Ebben az esetben a becsült modell:

$$\hat{y} = 4.85 + 4.91 \cdot 10^{-5} \cdot x$$

$$\text{Tehát } \theta = [\theta_0, \theta_1] = [4.85, 4.91 \cdot 10^{-5}]$$

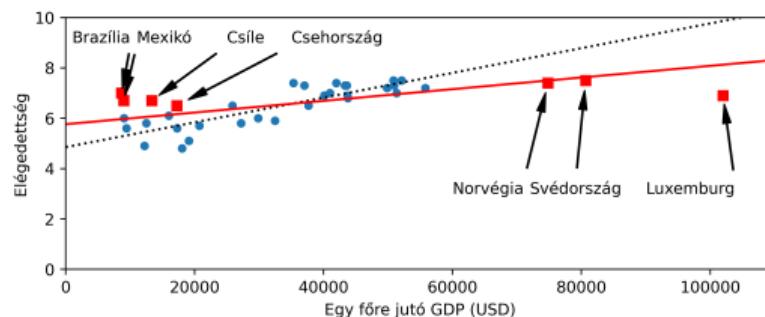


# Nem reprezentatív vagy hiányos adatok

Érdemes megfigyelni mi történik, ha több ország is hozzáadódik a mintához, amik eddig nem szerepelnek benne. Az illesztett modell egy szignifikáns változáson megy keresztül:

$$\hat{y} = 5.8 + 2.31 \cdot 10^{-5}$$


A modell változása annak a következménye, hogy az előző minta **nem volt megfelelően reprezentatív** az összes országra való tekintettel.



# A túltanulás problémája

A túltanulás onnan ered, hogy az **illesztett modellnek túlságosan magas a szabadságfoka**, vagy túl sok iteráción keresztül folyik a tanítás.

A túltanult modell **nagyon pontosan képes illeszkedni a tanító adatokra**, de nem fog jól teljesíteni a teszt adatokon. Emiatt rossz általánosító képességekkel fog rendelkezni.



1 A gépi tanulás kihívásai

2 Polinomiális regresszió


3 Regularizált modellek

4 Módszertan

# Polinomiális adatok

A valóságban nagyon kevés olyan adathalmaz létezik, amik leírhatók egy lineáris modellel

Ennek megfelelően szükség van komplexebb, nagyobb paraméterszámmal rendelkező modellekre, mint a polinomiális regresszor modellek.



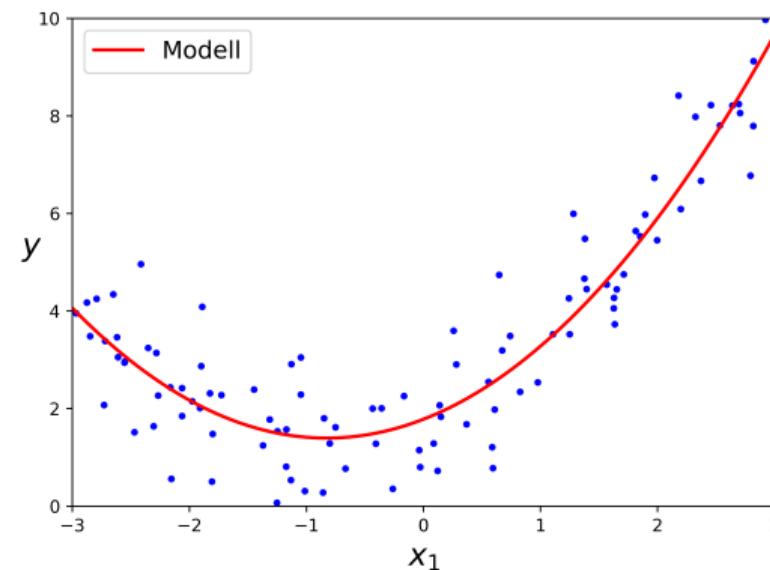
# Polinomiális adatok

## Polinomiális regresszor modell

Olyan típusú regressziós analízis, ahol a kapcsolat az  $x$  és  $y$  változók között **polinomok segítségével van modellezve**.

A modell magában foglalja a **független változók magasabb rendű hatványait** és azok interakcióját is. Általános formája:

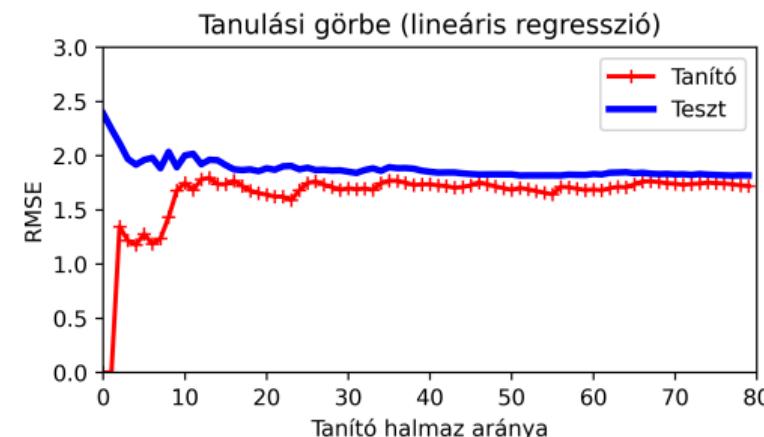
$$\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \cdots + \theta_n x^n$$



# Tanulási görbe lineáris és polinomiális esetben

A tanulási görbe azt mutatja meg, hogy az adott modellnek mekkora a hibája a tanító és teszt adatokon, a tanító adatok mennyiségének függvényében.

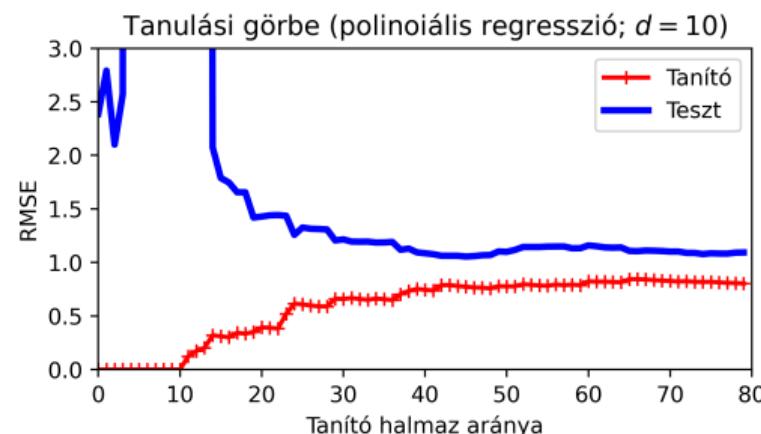
A polinomikus modellnek **magasabb a szabadságfoka**, ezért **alacsonyabb hibát képes elérni** ugyanazon az adathalmazon. Viszont ebben az esetben fennáll a túltanulás kockázata.



# Tanulási görbe lineáris és polinomiális esetben

A tanulási görbe azt mutatja meg, hogy az adott modellnek mekkora a hibája a tanító és teszt adatokon, a tanító adatok mennyiségének függvényében.

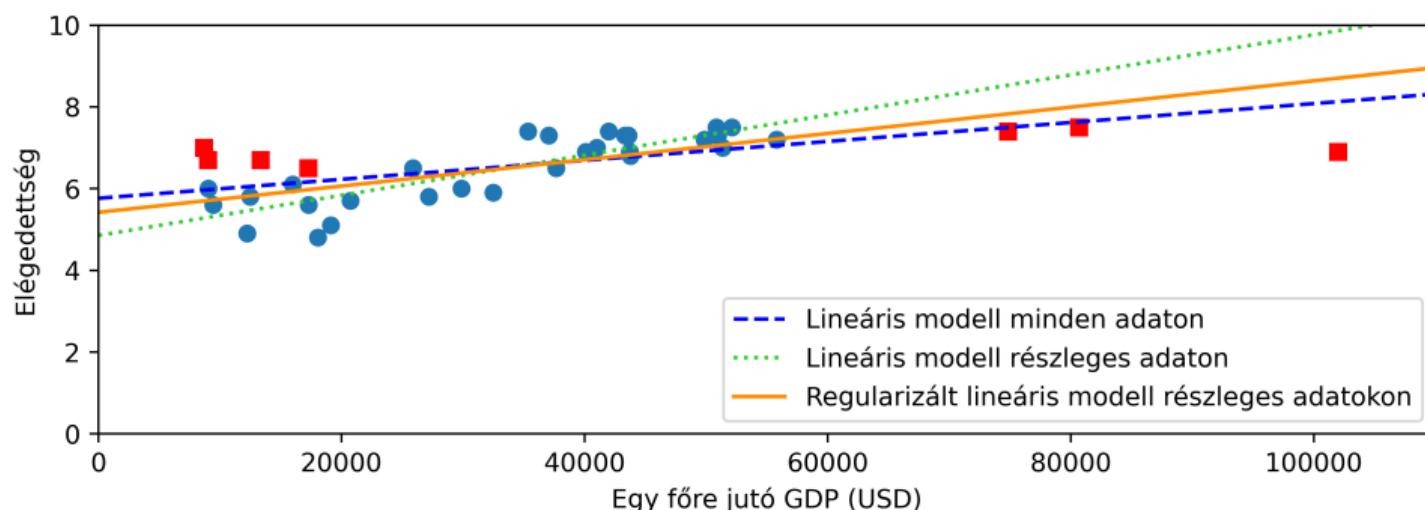
A polinomikus modellnek **magasabb a szabadságfoka**, ezért **alacsonyabb hibát képes elérni** ugyanazon az adathalmazon. Viszont ebben az esetben fennáll a túltanulás kockázata.



# Regularizáció

## Regularizáció

Gépi tanulásban és a statisztikai modellezésben egy technika, amelynek célja, hogy csökkentse a modell túlillesztését és javítsa a modell általánosító képességét új adatokra azáltal, hogy **segít a modell súlyait alacsonyan tartani**.



## 1 A gépi tanulás kihívásai

## 2 Polinomiális regresszió

## 3 Regularizált modellek

## 4 Módszertan

# Ridge regresszió

A lineáris regresszió regularizált változata, más néven Tikhonov regularizáció. Az algoritmus a függvény pontos illesztése mellett **célja a súlyokat a lehető legalacsonyabban tartani.**

Ezt úgy éri el, hogy a tanítási fázisban bevezet egy **regularizációs büntetőkifejezést**, és hozzáadja a már meglévő költségfüggvényhez.

## A Ridge költségfüggvénye

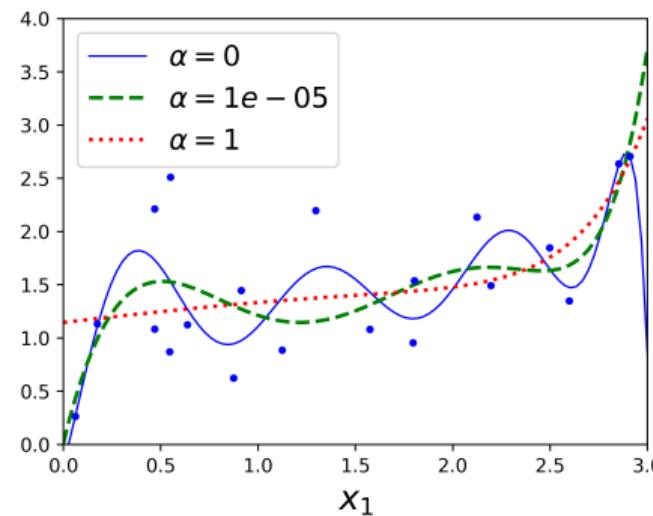

$$J(\theta) = MSE(\theta) + \alpha \sum \theta^2$$

Ahol:

- $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$  az átlagos eltérés-négyzet
- $\sum \theta^2$  az  $\ell_2$  norma büntetőkifejezés
- $\alpha$  a regularizáció mértékét adó együttható
- $\theta$  a paraméterek vektora

# Ridge a gyakorlatban

A két ábrán különböző  $\alpha$  paraméterrel tanított regularizált modellek láthatók. A bal oldali diagramon lineáris modellek, a jobb oldalon pedig polinomiális függvények illeszkednek az adathalmazra. Minél nagyobb az  $\alpha$ , annál általánosabb az modell.



# LASSO regresszió

A LASSO (**L**east **A**solute **S**hrinkage and **S**election **O**perator) regresszió a ridge-hez hasonlóan egy büntetőkifejezés segítségével regularizálja az illesztett modellt.

Ebben az esetben a büntetőkifejezés nem a paraméterek négyzetének összege, hanem az abszolút értékének.

## A LASSO költségfüggvénye

$$J(\theta) = MSE(\theta) + \alpha \sum |\theta|$$

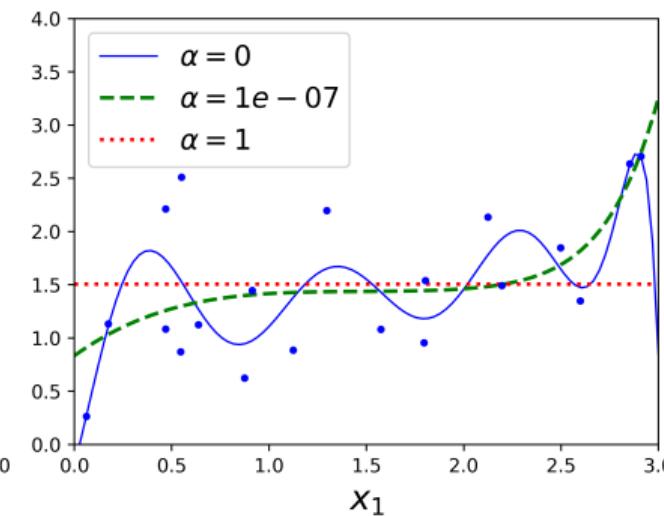
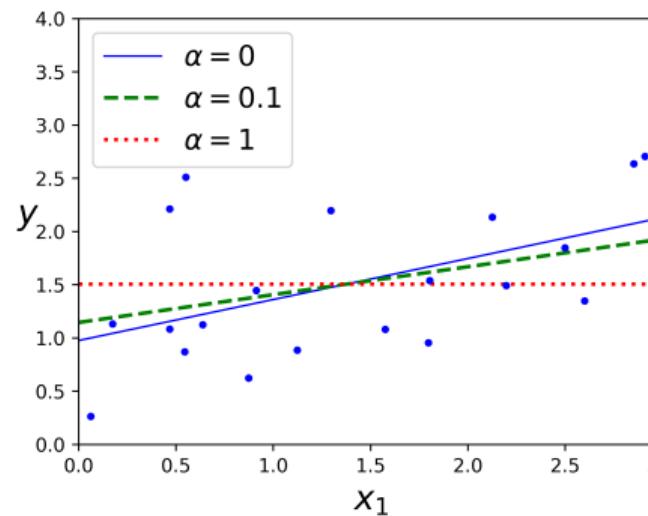
Ahol:

- $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$  az átlagos eltérés-négyzet
- $\sum |\theta|$  az  $\ell_1$  norma büntetőkifejezés
- $\alpha$  a regularizáció mértékét adó együttható
- $\theta$  a paraméterek vektora

# LASSO a gyakorlatban

A LASSO a regularizáláció mellett elvégzi a jellemzőkiválasztás műveletét is. A felesleges paramétereket eliminálja, tehát 0 értékeket ad nekik.


Az így létrejövő modellben kevés lesz a nem nulla súly.



# $\ell_1$ és $\ell_2$ norma

A LASSO büntetőkifejezése az  $\ell_1$  normát, a ridge pedig az  $\ell_2$  normát használja.

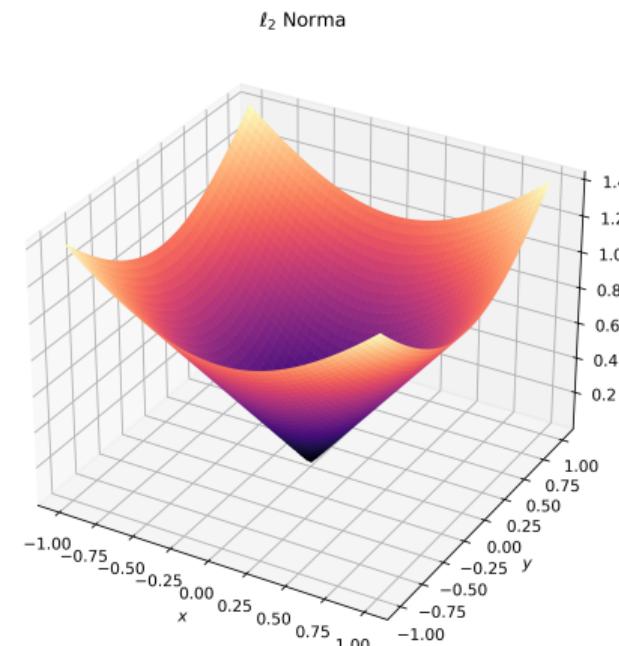
- A LASSO jobban teljesít kevés független változó esetén
- A LASSO végez jellemzőkiválasztást
- A LASSO az egymással korreláló változók közül egyet hagy meg
- A ridge az egymással korreláló változókat együtt kezeli
- A ridge jobban teljesít, amikor minden független változó befolyásolja az outputot



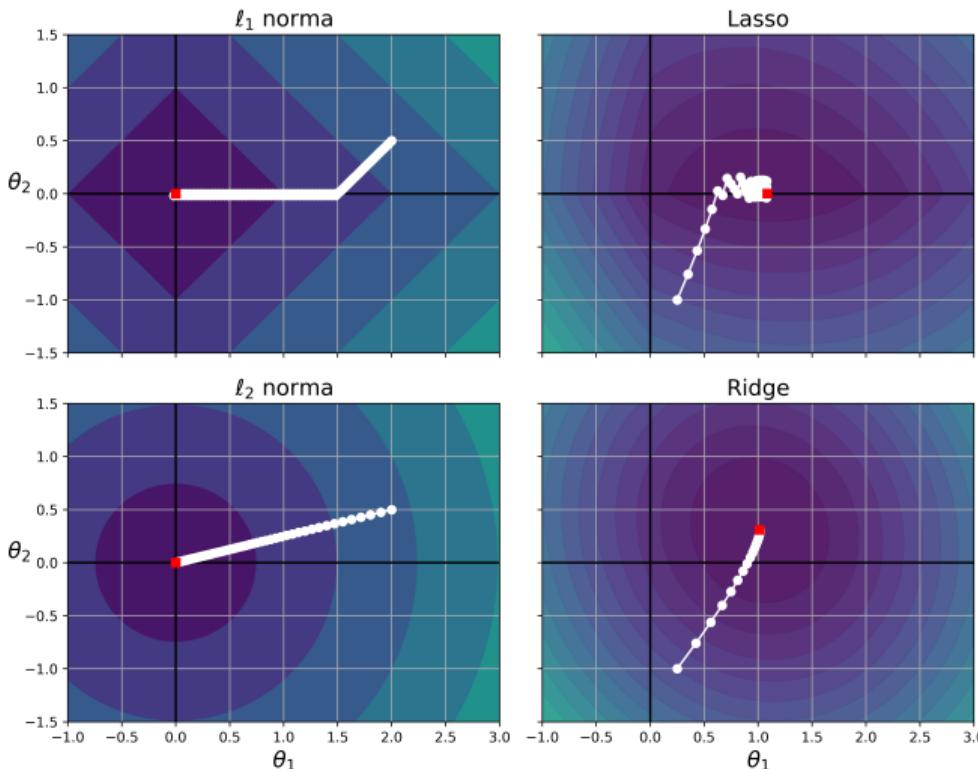
# $\ell_1$ és $\ell_2$ norma

A LASSO büntetőkifejezése az  $\ell_1$  normát, a ridge pedig az  $\ell_2$  normát használja.

- A LASSO jobban teljesít kevés független változó esetén
- A LASSO végez jellemzőkiválasztást
- A LASSO az egymással korreláló változók közül egyet hagy meg
- A ridge az egymással korreláló változókat együtt kezeli
- A ridge jobban teljesít, amikor minden független változó befolyásolja az outputot



## Gradiens ereszkedés LASSO és ridge regularizált függvényeken



# Elasztikus hálók [demo]

Az elasztikus háló egy **arányosságot definiál a LASSO és ridge modellek között**. A büntetőkifejezés egy keveréke a LASSO és ridge költségfüggvényeinek egy adott  $r$  keverési arány szerint.

Ha  $r = 0$  az elasztikus háló megegyezik a ridge modellel, ha  $r = 1$  akkor megegyezik a LASSO függvényel.

## Az elasztikus háló költségfüggvénye

$$\begin{aligned} J(\theta) &= MSE(\theta) + r \cdot \alpha \cdot \sum |\theta| + (1 - r) \cdot \alpha \cdot \sum \theta^2 = \\ &= MSE(\theta) + r \cdot \alpha \cdot \ell_1 + (1 - r) \cdot \alpha \cdot \ell_2 \end{aligned}$$

- $MSE(\theta)$ : Átlagos eltérés-négyzet
- $r \in [0, 1]$ : Keverési arány
- $\alpha$ : Regularizációs együttható

## 1 A gépi tanulás kihívásai

## 2 Polinomiális regresszió

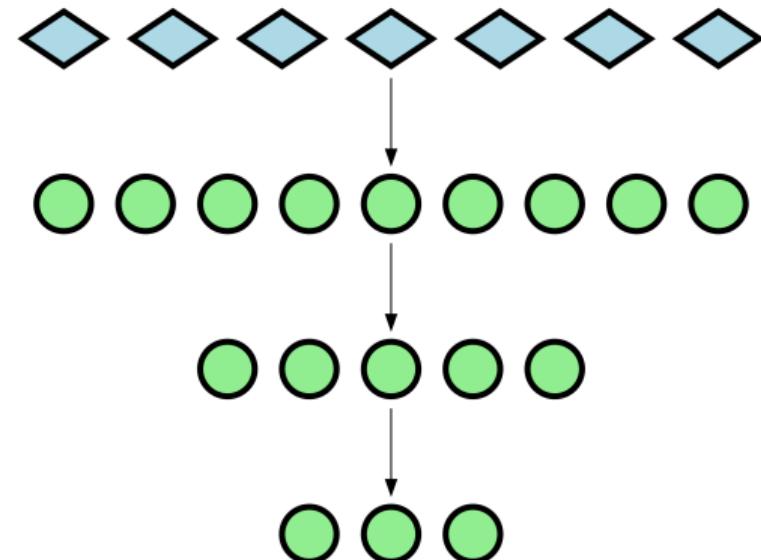
## 3 Regularizált modellek

## 4 Módszertan

# Jellemző összevonás és kiválasztás

## Jellemző összevonás

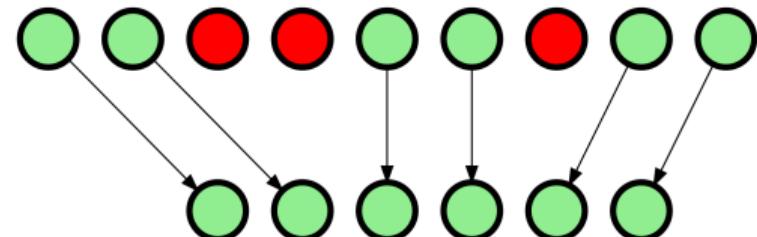
Jellemzők összevonása során meglévő változók alapján új változók kerülnek létrehozásra valamilyen aggregációs függvény vagy más eljárás alapján pl. főkomponenselemezés.



# Jellemző összevonás és kiválasztás

## Jellemző kiválasztás


A jellemzők kiválasztása során változók közül eldobásra kerülnek azok, amelyekre nincs szükség a modellezés szempontjából valamilyen metrika szerint.



# Jellemzők kiválasztásának lehetséges módjai

## Szűrés


Nem tesztel adott algoritmust, csak egy módszertan szerint fontossági sorrendet definiál a változók között, és az egy küszöbérték alattiakat elveti.



# Jellemzők kiválasztásának lehetséges módjai

## Iteratív

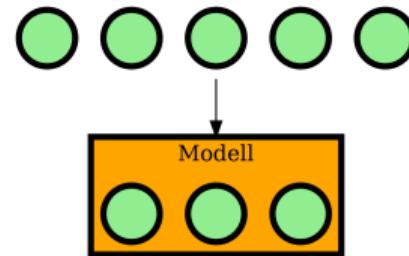
Specifikus modelleket kiértékel a jellemzők különböző részhalmazai szerint, majd azt választja ki amelyik a legjobb eredményt adja.



# Jellemzők kiválasztásának lehetséges módjai

## Beágyazott

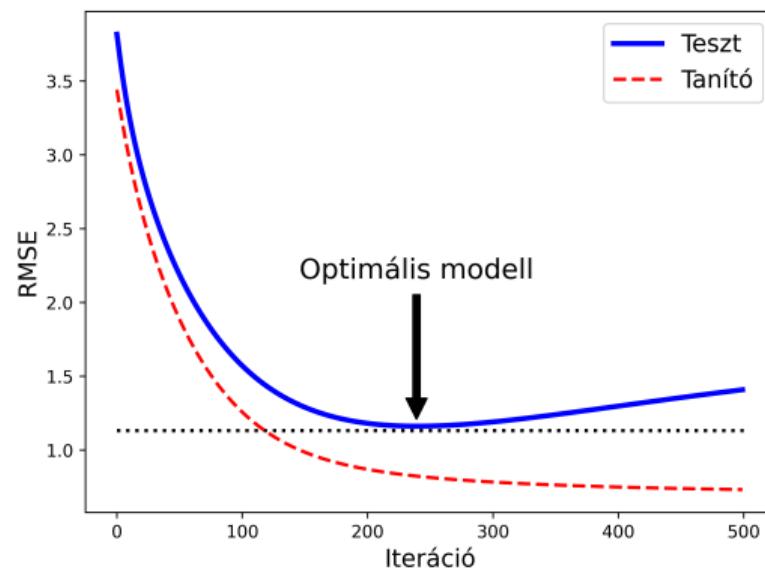
Minden technika ide tartozik, ami a tanítási fázisban jellemzőkiválasztást végez. Pl.: LASSO.



# Korai leállás

A korai leállás egy olyan technika gépi tanulásban amely segít megakadályozni a túltanulást egy tanítási folyamat során.

Ezáltal leállítja a tanítást, amint a hálózat teljesítménye elkezd romlani, vagy nem javul tovább a validációs adatkészleten.



# *k*-hajtásos keresztvalidáció

A technika az eredeti adatkészletet *k* egyenlő részre osztja, **majd minden iterációban egy különböző részhalmazt használ tesztelésre, a többöt pedig tanításra.**

Ez lehetővé teszi a **modell általánosító képességének pontosabb becslését.**

